PHYSICAL AI · VISION-LLM 최종 프로젝트 03

where-did-i-put-it?

1인칭 카메라가 대신 기억하고, 물어보면
말로 알려주는 물건 찾기 도우미

202434616 박진영

내가 본 건, 카메라도 봤다

휴대폰, 마우스… 방금 어디 뒀는지 기억이 안 난다

몸에 단 카메라는 내가 물건을 내려놓는 순간을 같이 봤다

카메라가 물건을 **마지막으로 본 장면**을 대신 기억하고

사람은 **말로 물어보기만** 하면 된다

이런 대화

나 마우스 어디 뒀지?

도우미 마우스는 키보드 근처에 두었습니다.

객체 탐지 → 이벤트 감지 → 음성 입력 → 음성 출력을 하나의 파이프라인으로

프로그램 두 개, 기억 파일 하나

① vision_tracker.py — 계속 실행하며 기록

USB 카메라
몸에 단 1인칭 시점
640×480

YOLO11n INT8
휴대폰·마우스
+ 주변 물건 10종

이벤트 판단
보이면 '봄'
3초 안 보이면 '사라짐'

item_memory.json
주변 물건 목록
+ 초록 박스 사진

질문할 때 읽기

② voice_assistant.py — 질문할 때 응답

마이크 → STT
5초 녹음
Whisper 받아쓰기

Gemma ①
찾는 물건 고르기
없으면 '본 적 없어요'

Gemma ②
기억 문장 + 사진
→ 위치 설명

Piper TTS
한국어 음성
→ 스피커

1인칭이라 화면 좌표 대신 **주변 물건 + 사진**으로 위치를 기억 · 기억에 없는 물건은 Gemma를 거치지 않고 '본 적이 없어요'

Jetson에서 실제로 돌려본 결과

질문	답변	응답 시간
마우스 어디 뒀지?	마우스는 키보드 근처에 두었습니다.	3.0초
내 핸드폰 어디 있어?	핸드폰은 손에 들려 있습니다.	4.0초
지갑 어디 있어?	그 물건은 아직 본 적이 없어요.	0.6초

마우스 — 주변 물건 기록(키보드)으로 위치를 설명

휴대폰 — 주변 기록이 없어도 마지막 사진만 보고 답함

지갑 — 기억에 없으므로 Gemma 없이 고정 답변

첫 질문 지연(약 32초)은 시작할 때 Gemma를 한 번 미리 실행해 4초로 줄임

더 정확하게 기억하려면

개선 ①

손에 든 물건은 기록에서 제외

- 손이 보인다 = 지금 사용 중이라는 뜻
- 지금은 손에 든 장면도 마지막 장면으로 저장돼 “손에 들려 있습니다”라고 답함
- MediaPipe Hands로 손과 겹친 물건은 기록 제외
- 내려놓은 장면만 기억

개선 ②

프레임 제한이 걸려도 YOLO 정확도가 우선

- 1인칭 영상은 흐리고, 가깝고, 각도가 심함
- 휴대폰 확신도가 0.18까지 떨어져 기준을 0.5 → 0.3으로 낮춤
- 마지막 장면 한 장만 필요 → FPS보다 정확도
- yolo11s·m 같은 큰 모델 또는 1인칭 데이터로 파인튜닝